Финансовый университет при Правительстве Российской Федерации

Прикладные задачи машинного обучения

Лабораторная работа 1
Сравнение языковых моделей на русскоязычном MIRACL

Оценка релевантности и последовательное взаимодействие с поиском

Группа ПМ23-2

Москва 2026

Тема ВКР: «Разработка языковой модели для многошагового взаимодействия с поисковыми инструментами агентной системы».

Проведено сравнение восьми локальных LLM в zero-shot и few-shot на общем наборе из 40 запросов и 416 оценок релевантности. По правилу, зафиксированному до test, выбрана Qwen3 14B в режиме few-shot. На test её Macro-F1 равен 0,769 с 95% ДИ [0,709; 0,823]. Отдельно выполнены поиск по корпусу из 41 007 пассажей и реальная LoRA-адаптация малой модели.

Все таблицы формируются из сохранённых ответов моделей. Числа из демонстрационного примера методички в результаты не переносились. Дата эксперимента 18 октября 2026 года.

1 Постановка исследования

Цель работы — выбрать доступную языковую модель для компонента, который оценивает найденные свидетельства и взаимодействует с поиском. Для ВКР важно отделять качество релевантности от способности строить многошаговую поисковую траекторию.

Какая из восьми локальных LLM даёт лучший компромисс Macro-F1, MCC, Brier, latency и памяти на MIRACL ru и как выбранная на validation модель работает при поиске в отдельном ограниченном корпусе?

Основной эксперимент — бинарная оценка релевантности: каждому запросу предъявляется весь его размеченный пул пассажей без меток. Одна генерация возвращает список оценок для всех кандидатов. Это контекстная классификация и условный reranking; модель не извлекает документы из корпуса на этом этапе.

Отдельный прикладной эксперимент использует настоящий фиксированный индекс из 41 007 пассажей. Следующий поисковый запрос зависит от реальной предыдущей выдачи, а политика может остановиться. Это ограниченный инструментальный поиск с обратной связью. MIRACL не содержит эталонных агентных траекторий и не доказывает качество multi-hop reasoning.

H1. Few-shot улучшает Macro-F1 относительно zero-shot при общем тесте; эффект проверяется парным bootstrap по запросам, без заранее предполагаемого выигрыша.

H2. Выбор по качеству, заявленной уверенности и ресурсам может отличаться от выбора по одному Macro-F1.

H3. Поиск с обратной связью может увеличить полноту, но также терять ограничения и ухудшать nDCG; эффект проверяется отдельно на 20 новых запросах.

Аудит предыдущей работы выявил незаполненные результаты, отсутствие реальных запусков, слабый паспорт данных, синтетические few-shot примеры и BM25 fallback в метриках LLM. Старые материалы сохранены в previous. Итоговая работа использует реальные демонстрации из train, самостоятельные отказы и отдельный поисковый опыт.

2 Обзор литературы

2.1 Поиск и отбор источников

Поисковый запрос: ("large language model" OR LLM) AND (retrieval OR reranking OR "search agent" OR "multi-step") AND (MIRACL OR Russian OR multilingual). Для адаптации отдельно использовались LoRA и QLoRA. Проверялись ACL Anthology, arXiv, OpenReview, proceedings и авторские репозитории.

PRISMA-подобный журнал описывает целенаправленный отбор, а не исчерпывающий систематический обзор. Рассмотрено 20 явно перечисленных кандидатов; включено 15, исключено 5. Объём всей поисковой выдачи и число её дублей не подсчитывались. Для ключевых работ сверены релевантные разделы протокола и метрик; для BEIR и RuBQ 2.0 глубина чтения ограничена первичными описаниями и авторским кодом.

Этап	Число	Основание
Рассмотренные кандидаты	20	Оригинальные работы по retrieval, агентам, PEFT и русским данным
Включённые работы	15	Задают данные, методы, протокол или ограничения лабораторной
Исключённые работы	5	Дублирующая версия RuBQ, вторичный обзор и менее близкие методы

2.2 Сопоставление подходов

Базовая retrieval-литература [1–3] показывает, что поисковик нужно оценивать по реальному корпусу и фиксированным qrels. MIRACL даёт русскоязычный материал, BEIR обосновывает необходимость устойчивого baseline и анализа переноса, а DPR отделяет поиск фрагментов от последующей работы reader.

RAG [4] добавляет генератор к внешней памяти. Для ВКР важно не смешивать качество сформированного ответа и полноту извлечения. Даже корректная переформулировка не гарантирует ответ, а убедительный ответ не доказывает нахождение нужного свидетельства.

HyDE и Rewrite-Retrieve-Read [6–7] показывают два разных пути использования LLM до поиска: генерировать гипотетический документ для плотного энкодера или менять непосредственно запрос. Второй путь доступнее для локального опыта с фиксированным поисковиком. При этом опубликованные QA-метрики не заменяют MIRACL qrels.

RankGPT [8] относится к reranking. Его наблюдение о зависимости от порядка кандидатов важно для аудита прежней реализации. Если каждому запросу заранее гарантировать правильный документ среди нескольких лёгких отрицательных, получится искусственно облегчённая задача. Candidate recall задаёт потолок последующего ранжирования.

Baleen и ReAct [5, 9] дают основания называть поиск многошаговым: новый шаг учитывает ранее найденное. Search-R1 и ReSearch [10–11] делают такую политику объектом обучения. Их multi-hop QA-результаты нельзя автоматически воспроизвести на MIRACL, где нет эталонных траекторий и ответов.

LoRA и QLoRA [12–13] позволяют постобучать доступные модели при ограниченной памяти. Они не являются способом повысить retrieval без отдельного опыта. Необходимы train/validation/test, контроль данных и оценка адаптированной модели по тому же протоколу.

Отечественные ruMTEB и RuBQ 2.0 [14–15] связывают исследование с русским языком. ruMTEB явно различает retrieval и reranking и использует MIRACL. RuBQ добавляет ответы и структурные запросы, поэтому полезен для следующего этапа QA; сложность SPARQL не заменяет проверку реальных действий агента.

В рассмотренных работах качество поиска, reranking и обучение поисковой политики оцениваются в разных условиях. Для локального прототипа остаётся прикладной вопрос: какая доступная LLM лучше оценивает релевантность русских пассажей с учётом качества, калибровки заявленной уверенности и ресурсов, и переносится ли этот выбор на последовательное уточнение поискового запроса.

Практический вывод обзора: качество поиска следует оценивать отдельно от генерации, сравнение вести на одинаковых данных, а обучение политики требует самостоятельного опыта с траекториями. Публикационные результаты разных датасетов не используются как ожидаемые показатели лабораторной.

2.3 Матрица пятнадцати работ

Ниже объединены задача и архитектура, данные и протокол, метрики, ограничения и идея репликации. Полная машиночитаемая матрица с авторскими ссылками и кодом находится в report/literature_matrix.csv. Номера соответствуют списку источников.

Работа	Задача и архитектура	Данные и протокол	Метрики	Ограничение и репликация
[1] MIRACL 2023	Монолингвальный поиск релевантных фрагментов Wikipedia на 18 языках. Единый набор запросов, корпуса и бинарных qrels; сравниваются BM25, mDPR, гибридные и многоязычные методы.	Wikipedia; запросы и оценки релевантности размечены носителями языка. Русский язык представлен отдельными train/dev. Полноценный поиск по корпусу соответствующего языка; обучение на train и оценка на фиксированном dev/test.	nDCG@10; Recall@100	Разметка релевантности не задаёт цепочки действий, необходимое число шагов и эталонный ответ. Неполные qrels не означают, что каждый неразмеченный документ нерелевантен. Репликация: Индексировать фиксированный русский корпус, хранить его хеш и qrels, сравнить исходный запрос с LLM-переформулировкой.
[2] BEIR 2021	Проверка переноса retrieval-моделей между доменами и задачами. Сопоставление лексических, разреженных, плотных, late-interaction методов и rerankers на общем наборе.	18 разнородных корпусов: QA, научные тексты, аргументация, проверка фактов и другие задачи. Zero-shot перенос без настройки на тестовые qrels каждого целевого набора.	nDCG@10; Recall@k	Преимущественно англоязычные задачи; среднее по разным наборам скрывает отдельные провалы. Репликация: Сохранить сильную поисковую базу и парные результаты по запросам; не выбирать модель только по одному среднему.
[3] DPR 2020	Поиск фрагментов с ответом для open-domain QA. Два BERT-энкодера для вопроса и фрагмента; скалярное произведение и индекс плотных векторов.	Wikipedia; Natural Questions, TriviaQA и другие QA-наборы. Контрастивное обучение на положительных парах, in-batch и сложных отрицательных примерах; отдельно оцениваются retrieval и reader.	Top-k passage retrieval accuracy; Exact Match ответа	Top-k accuracy наличия ответа отличается от Recall@k по всем qrels; обучение англоязычного DPR не гарантирует качество на русском. Репликация: Использовать многоязычный энкодер как независимую поисковую базу при наличии ресурсов.
[4] RAG 2020	Генерация ответа с доступом к внешним знаниям. DPR и BART; RAG-Sequence и RAG-Token по-разному маргинализуют извлечённые документы.	Индекс Wikipedia и несколько knowledge-intensive QA/генеративных задач. Дообучение retrieval-augmented модели и сравнение с параметрическими и extractive QA-системами.	Exact Match в QA; Метрики соответствующей downstream-задачи	Генеративное качество не тождественно retrieval-качеству. Оригинальная архитектура не задаёт автономную многошаговую политику поиска. Репликация: Оценивать поисковый этап отдельно; для QA добавить верифицируемые ответы и цитаты.
[5] Baleen 2021	Сбор нескольких фрагментов доказательств для QA и проверки утверждений. Condensed retrieval: сжатие найденных фактов после шага, focused late-interaction retriever FLIPR и latent hop ordering.	HotpotQA и HoVer; Wikipedia. Последовательное извлечение свидетельств; на HoVer различаются утверждения с 2–4 переходами; выполняются абляции числа шагов.	Retrieval@100: доля запросов со всеми нужными фрагментами; Passage EM/F1; Sentence EM/F1; Verification Accuracy	Нужны наборы с составными свидетельствами и существенный индекс; нельзя заменить полный протокол ранжированием заранее подложенного ответа. Репликация: Логировать запрос, наблюдение и новые документы после каждого шага; для проверки multi-hop использовать HotpotQA/HoVer.

Работа	Задача и архитектура	Данные и протокол	Метрики	Ограничение и репликация
[6] HyDE 2023	Dense retrieval без разметки релевантности целевой задачи. LLM создаёт гипотетический ответный документ; Contriever кодирует его и ищет реальные документы.	BEIR/TREC и неанглоязычные retrieval-задачи. Zero-shot генератор и необучаемый на qrels целевой задачи энкодер; сравнение с исходным dense retrieval.	nDCG@10; Recall@k	Гипотетический документ не является доказательством; ошибка LLM способна сместить поиск. HyDE — не reranking и сам по себе не агент. Репликация: При доступном dense-индексе сравнить исходный запрос и embedding гипотетического текста на одних qrels.
[7] Rewrite-Retrieve-Read 2023	Согласование пользовательского вопроса с поисковиком и фиксированным LLM-reader. LLM-переформулировщик → web retrieval → reader; небольшой rewriter может обучаться по обратной связи reader.	HotpotQA, AmbigNQ, PopQA и MMLU. Сопоставляются direct, retrieve-then-read, frozen LLM rewriter и trainable rewriter при фиксированном reader.	Exact Match; F1 ответа	Основные метрики относятся к ответу, а не к MIRACL qrels; web-корпус меняется, а ошибка reader влияет на reward. Репликация: Фиксировать локальный корпус и поисковик, сравнить zero-shot и few-shot rewrite; qrels не передавать LLM.
[8] RankGPT 2023	Переупорядочивание уже найденных фрагментов. Listwise permutation generation; окно кандидатов перемещается по исходному списку BM25; отдельно изучается дистилляция.	TREC DL19/20, BEIR, Mr.TyDi и NovelEval. Общие исходные кандидаты, сравнение инструкций и абляции порядка, размера окна и повторных проходов.	nDCG@1/5/10; Число токенов и API-запросов; Стоимость	Reranker не находит документ вне набора кандидатов. Слово agents в названии не доказывает multi-step tool use. Репликация: Получать кандидатов поиском, не подмешивать gold; отдельно сообщать candidate recall, ошибки формата и fallback.
[9] ReAct 2023	Решение задач с последовательными действиями во внешней среде. Цикл reasoning → action → observation; следующая команда зависит от полученного наблюдения.	HotpotQA, FEVER, ALFWorld, WebShop. Few-shot траектории и сравнение с reasoning-only/action-only; в статье также рассматривается обучение на успешных траекториях.	Exact Match в QA; Accuracy проверки фактов; Success rate интерактивных задач	Чувствительность к примерам, среде и длине траектории; успешность действий нельзя оценить одной ranking-метрикой. Репликация: Сохранить полный журнал вызовов инструмента, бюджет шагов и критерий остановки.
[10] Search-R1 2025	Обучение LLM самостоятельно вызывать поиск внутри рассуждения. PPO/GRPO с поисковым окружением; внешние найденные токены исключаются из loss; reward по правильности ответа.	Обучение NQ + HotpotQA; оценка NQ, TriviaQA, PopQA, HotpotQA, 2WikiMultiHopQA, MuSiQue, Bamboogle. Общие retriever, корпус, число извлекаемых фрагментов, тренировочные данные и семейства моделей; анализ base/instruct и числа вызовов.	Exact Match; Длина ответа; Валидные вызовы поиска	Англоязычные QA и существенные ресурсы RL; результат нельзя автоматически переносить на русский MIRACL. Репликация: Сначала проверить inference на доступном checkpoint; RL требует отдельного QA-набора с ответами и вычислительного бюджета.
[11] ReSearch 2025	Многошаговые QA с чередованием поиска и reasoning. RL-политика Qwen2.5; reward включает F1 ответа и корректность формата.	MuSiQue train; HotpotQA, 2WikiMultiHopQA, MuSiQue dev и Bamboogle test; Wikipedia 2018. Open-ended retrieval без готовых исходных контекстов QA; сравнение с No RAG, Naive RAG, Iter-RetGen и IRCoT.	Exact Match; LLM-as-a-judge correctness	F1 reward не совпадает с итоговой EM; LLM-judge добавляет зависимость от судьи. Эксперимент не русскоязычный. Репликация: Отделять reward обучения от независимой оценки; явно хранить search-budget и полные наблюдения.
[12] LoRA 2022	Адаптация большой предобученной модели с малым числом обучаемых параметров. Базовые веса заморожены; обучаются низкоранговые добавки к матрицам Transformer.	В статье языковые и генеративные бенчмарки с RoBERTa, DeBERTa, GPT-2 и GPT-3. Сопоставление с полным fine-tuning и другими адаптерами; исследование ранга и размещения обновлений.	GLUE Accuracy/Matthews/ Pearson по задаче; Метрики генерации; Число обучаемых параметров; Память	Экономия памяти не доказывает качество на retrieval и не устраняет необходимость отдельной validation. Репликация: Обучать адаптер только на train, подбирать параметры на validation и сохранять конфигурацию целевых модулей.

Работа	Задача и архитектура	Данные и протокол	Метрики	Ограничение и репликация
[13] QLoRA 2023	Дообучение LLM при ограниченной видеопамяти. Замороженная база в 4-битном NF4, trainable LoRA; double quantization и paged optimizers.	Instruction-tuning корпуса и наборы оценки диалоговых моделей; семейство Guanaco. Сравнение precision и способов квантизации, данных и размеров моделей при дообучении.	5-shot MMLU Accuracy; Потребление GPU-памяти; Оценка диалоговых ответов (human/GPT-4)	Часть оценки зависит от автоматического судьи; для конкретного GPU и backend совместимость и память проверяются экспериментом. Репликация: Если NF4-backend доступен, сопоставить один и тот же адаптерный протокол с FP16 LoRA; иначе честно выполнить обычный LoRA.
[14] ruMTEB 2025	Оценка русскоязычных embeddings в нескольких классах задач. ruMTEB и ru-en-RoSBERTa; адаптация словаря, контрастивное обучение и смешение русских/английских данных.	23 набора в 7 категориях; retrieval включает MIRACL, RuBQ и RiaNews. Единая реализация MTEB, корректные префиксы и pooling по моделям; раздельные retrieval/reranking-задачи.	nDCG@10 для retrieval; MAP@10 для reranking, кроме MIRACL; nDCG@10 для MIRACL reranking; Метрики остальных категорий	Это embedding-бенчмарк, а не оценка агента; обучение некоторых моделей уже включает MIRACL train. Репликация: Использовать зафиксированную реализацию и учитывать известную тренировочную экспозицию MIRACL.
[15] RuBQ 2.0 2021	Русскоязычные KBQA, чтение фрагментов и гибридные QA. Размеченные вопросы, SPARQL к Wikidata, ответы и ответосодержащие фрагменты Wikipedia.	2910 русских вопросов разной сложности; версия 2.0 расширяет исходный RuBQ. Отдельные KBQA и MRC baseline; оценка ответа и соответствия данным задачи.	Качество ответа в KBQA и MRC (численные baseline здесь не переносятся)	SPARQL-сложность не равна числу поисковых вызовов LLM; составная QA-разметка требует отдельного аудита. Репликация: Использовать как независимый русский QA-срез с ответами, проверив пересечения текстов и формулировок.

3 Данные и подготовка

Источник запросов и меток — официальный MIRACL ru. Метка 1 означает релевантный пассаж, 0 — оценённый нерелевантный пассаж; отсутствие оценки не означает метку 0. Исторические negative passages уже размечены людьми, случайные отрицательные примеры не подмешиваются.

Официальные topics/qrels закреплены на revision 5be20db9509754dadad47689368639fcec739c00. Тексты получены из компактного зеркала sohey1024/miracl-ru-corpus, revision 1fd7b335ab9be859040f664efb07b9665d4bf8ee. Его 41 007 ID в точности совпадают с объединением официальных ru train/dev qrels. Проверены все ID и метки; для 16 пересекающихся пассажей из 400 прочитанных официальных строк заголовки и тексты совпали полностью.

Карточки MIRACL и корпуса указывают Apache-2.0. У зеркала отдельная лицензия в карточке не указана; происхождение текстов — MIRACL/Wikipedia. Сохранены ссылки на первоисточник, ревизии и SHA256. Это ограничение происхождения зеркала, а не основание приписывать ему новую лицензию.

Часть	Источник	Запросы	Метки 1	Метки 0	Всего
train	official train	64	180	491	671
validation	official train	16	36	132	168
test	official dev	40	105	311	416
application	official dev	20	63	144	207

Train используется для демонстраций и LoRA; validation — для выбора модели и режима. Test открывается после фиксации выбора. Application — отдельные 20 запросов для переноса выбранного решения. Числовые query_id разных официальных split пересекаются, поэтому в коде используются пространства имён train: и dev:.

Выборка получена после сортировки ID и перемешивания с seed 42 для official train и 43 для official dev. Сохраняются первые подходящие запросы с обоими классами и не более 20 judgments. В рассмотренной последовательности исключены 51 запрос, не удовлетворяющий условиям, и 3 запроса с межвыборочным пересечением документа. Отбор не зависит от успеха моделей или сложности BM25.

Для утечек проверяются docid, нормализованные тексты, близкие тексты по Jaccard множеств токенных 3-шинглов при пороге 0,85 и близкие формулировки запросов. Между четырьмя использованными частями пересечений не найдено. Проверка охватывает выбранные данные, но не может исключить попадание Wikipedia или MIRACL в предобучение самих LLM.

Во всём корпусе найдено 108 групп точных нормализованных дублей, 127 повторных пассажей. Они сохраняют официальные ID; объединение нарушило бы qrels. Пустых текстов 0, пустых заголовков 0. Медиана длины пассажей корпуса — 643 символа. Временные метки наблюдений не предоставлены; разбиение групповое случайное, а не временное.

Изоляция выполнена по query_id, docid и текстам, а не по статьям Wikipedia целиком. Независимый аудит обнаружил одну общую статью между train и test при разных непохожих

пассажах. Утечки одинаковой пары нет, но полностью независимый перенос на новые статьи этим разбиением не проверяется.

В сохранённых данных тексты полные. Модель видит не более 900 символов пассажа; общий бюджет текстов — 14 000 символов. Заголовки ограничены 120 символами. У всех моделей одинаковые фрагменты и один детерминированно перемешанный порядок. Усечение может удалить ответ из конца документа; анализ ошибок отдельно учитывает исходную длину.

4 Единый протокол сравнения

4.1 Модели и ресурсы

Ollama ID	Размер	Квантование	Лицензия	Preflight tokens
qwen2.5-coder:1.5b	1.5B	Q4_K_M	Apache-2.0	5415
llama3.2:3b	3.2B	Q4_K_M	Llama 3.2 Community License	4866
gemma3:4b	3.9B	Q4_K_M	Gemma Terms	4355
phi3.5:3.8b	3.8B	Q4_0	MIT	5345
qwen2.5-coder:14b	14.8B	Q4_K_M	Apache-2.0	5415
qwen3:14b	14.8B	Q4_K_M	Apache-2.0	5402
qwen3:30b	30.5B	Q4_K_M	Apache-2.0	5396
qwen2.5-coder:32b	32.8B	Q4_K_M	Apache-2.0	5415

Измерения выполнены последовательно на NVIDIA RTX 3090 24 ГБ, Ryzen 7 5700X, Windows 10 и Ollama 0.40.4. Основной Python 3.10.20. Сравниваются конкретные локальные сборки и размеры, а не восемь независимых семейств. Большая доля Qwen обусловлена уже установленными весами. Различия квантования входят в ограничения системного сравнения; контрольная переквантизация всех моделей не выполнялась.

Проверка совместимости локальной Qwen3-VL показала продолжение рассуждения при think=false и исчерпание 384 токенов до финального JSON. Десять попыток сохранены отдельно; до открытия test модель заменена на Phi-3.5. Алиас claude-local с теми же весами, что Qwen2.5-Coder-14B, отдельной моделью не считается.

4.2 Генерация и контроль формата

Для каждой модели выполнены zero-shot и two-shot с одинаковыми двумя размеченными примерами из train: один положительный, один отрицательный. Демонстрационные оценки 0,9 и 0,1 — фиксированные якоря формата и направления уверенности, а не эталонные вероятности. Модель получает все фрагменты одного запроса одновременно; их оценки могут зависеть друг от друга.

Параметры: temperature 0, seed 42, контекст 8192, max_new_tokens 384, top_k 1, top_p 1, repeat_penalty 1. Thinking отключён там, где он поддерживается. JSON-схема задаёт ровно одно число [0;1] на каждый фрагмент. Тем самым доля невалидных ответов измеряется в условиях ограниченного декодирования; она не характеризует свободное следование JSON-инструкции.

Перед измерением каждой модели выполнен прогрев на самом длинном по тексту few-shot примере из train и проверено число входных токенов. Для каждого запроса сохраняются

полный prompt, хеш, сырой ответ, счётчики токенов, latency и digest весов. Ключ кэша включает prompt, данные, параметры, модель и версию сервера. Автоматические исправления ответа и повторные попытки не используются.

Невалидный ответ означает отказ сразу по всему запросу. Для эксплуатационного Macro-F1 отказ считается отдельной предсказанной меткой 2 и штрафует обе целевые категории. MCC, Brier и ECE считаются только по валидным ответам вместе с покрытием. В reranking отказ даёт пустую выдачу и нулевую метрику. BM25 fallback не добавляется к результату LLM.

4.3 Метрики и статистика

Основной показатель — Macro-F1 двух классов при пороге $p \geq 0{,}5$. Дополнительно измеряются MCC, precision/recall/F1 релевантного класса, Brier и ECE с 10 фиксированными интервалами. Brier — среднее $(p - y)^2$; ECE сопоставляет среднюю заявленную оценку и частоту релевантности. Это калибровка сообщаемой моделью уверенности, а не оценка её token posterior.

Вспомогательные nDCG@10, MRR@10 и Recall@3/10 считаются после сортировки этих оценок внутри judged pool. Ничьи разрешаются фиксированным перемешанным порядком. В test у большинства запросов ровно 10 кандидатов, поэтому Recall@10 близок к насыщению и не доказывает полноту поиска. В глобальном поисковом опыте Recall@10 имеет другое, содержательное значение.

95% интервалы построены percentile bootstrap из 2000 повторов по целым query_id, seed 42. Пары zero/few сравниваются на одинаковых запросах. Интервалы не корректируются за множество сравнений и не дают основания объявлять статистического победителя по одному пересечению CI. Latency — end-to-end время тёплого запроса с подготовленным prompt; загрузка и прогрев исключены и сохранены отдельно. Память — resident size_vram Ollama после прогрева; журнал GPU дополнительно записывается каждые две секунды, это не непрерывный аппаратный пик.

5 Результаты на общем тесте

Каждая строка относится к тем же 40 запросам и 416 judgments. Режим Z — zero-shot, F — few-shot. Интервалы относятся к эксплуатационному Macro-F1; Brier и ECE — к валидным ответам.

Модель	Реж.	Macro-F1 и 95% ДИ	MCC	Brier	ECE	Отказ %
Coder 1.5B	Z	0,428 [0,411; 0,443]	0,000	0,252	0,252	0,0
Coder 1.5B	F	0,428 [0,411; 0,443]	0,000	0,252	0,252	0,0
Llama 3.2 3B	Z	0,575 [0,528; 0,622]	0,159	0,288	0,288	0,0
Llama 3.2 3B	F	0,498 [0,439; 0,557]	0,013	0,361	0,353	0,0
Gemma 3 4B	Z	0,583 [0,528; 0,637]	0,257	0,280	0,283	0,0
Gemma 3 4B	F	0,560 [0,503; 0,612]	0,194	0,288	0,269	0,0
Phi 3.5 3.8B	Z	0,513 [0,466; 0,559]	0,079	0,272	0,271	0,0
Phi 3.5 3.8B	F	0,458 [0,422; 0,501]	0,032	0,254	0,253	0,0
Coder 14B	Z	0,781 [0,722; 0,837]	0,562	0,159	0,155	0,0
Coder 14B	F	0,733 [0,664; 0,801]	0,469	0,186	0,188	0,0
Qwen3 14B	Z	0,791 [0,736; 0,843]	0,583	0,152	0,155	0,0
Qwen3 14B	F	0,769 [0,709; 0,823]	0,544	0,160	0,122	0,0

Модель	Реж.	Macro-F1 и 95% ДИ	MCC	Brier	ECE	Отказ %
Qwen3 30B MoE	Z	0,787 [0,735; 0,840]	0,580	0,144	0,144	0,0
Qwen3 30B MoE	F	0,775 [0,729; 0,822]	0,552	0,153	0,149	0,0
Coder 32B	Z	0,823 [0,768; 0,871]	0,649	0,115	0,104	0,0
Coder 32B	F	0,807 [0,751; 0,854]	0,618	0,122	0,095	0,0

Baseline	Macro-F1	Brier	ECE
majority_0	0,428	0,252	0,252
constant_train_prior	0,428	0,189	0,016

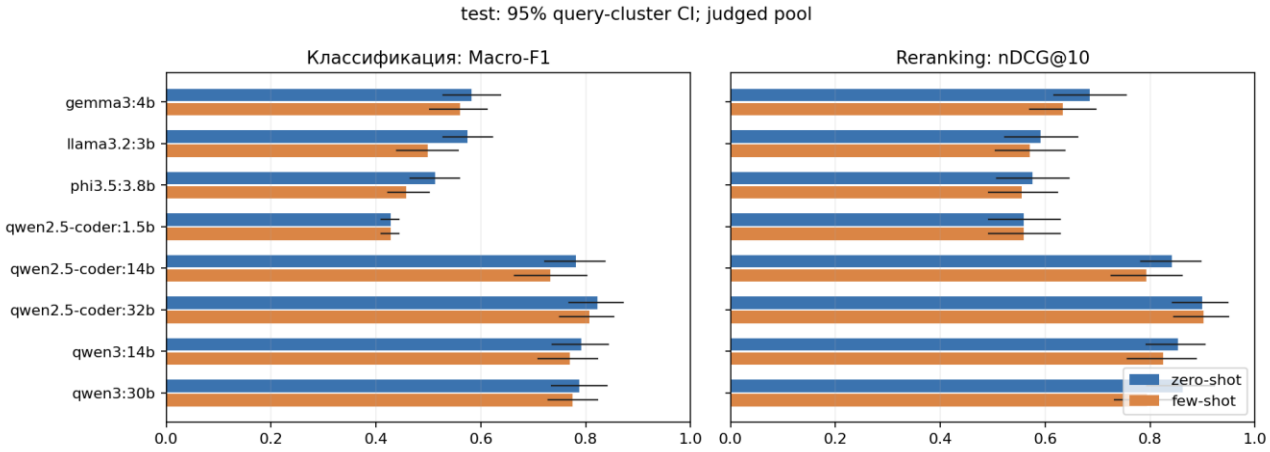


Рисунок 1 Macro-F1 восьми моделей и 95% интервалы по query_id

Модель	Реж.	p50 с	p95 с	Resident VRAM ГиБ	tokens/s
Coder 1.5B	Z	0,73	0,84	1,27	142,3
Coder 1.5B	F	0,83	0,92	1,27	143,7
Llama 3.2 3B	Z	1,05	1,21	2,90	112,6
Llama 3.2 3B	F	1,21	1,33	2,90	110,3
Gemma 3 4B	Z	1,44	1,65	2,83	76,5
Gemma 3 4B	F	1,67	1,80	2,83	75,0
Phi 3.5 3.8B	Z	1,57	2,00	5,13	85,4
Phi 3.5 3.8B	F	1,77	2,04	5,13	81,4
Coder 14B	Z	3,06	3,22	9,71	55,0
Coder 14B	F	3,06	3,25	9,71	60,3
Qwen3 14B	Z	2,82	3,06	9,77	61,6
Qwen3 14B	F	3,03	3,36	9,77	62,3
Qwen3 30B MoE	Z	2,07	2,43	17,95	87,7
Qwen3 30B MoE	F	2,23	2,54	17,95	88,1
Coder 32B	Z	5,10	5,63	20,28	32,9
Coder 32B	F	5,22	5,93	20,28	32,6

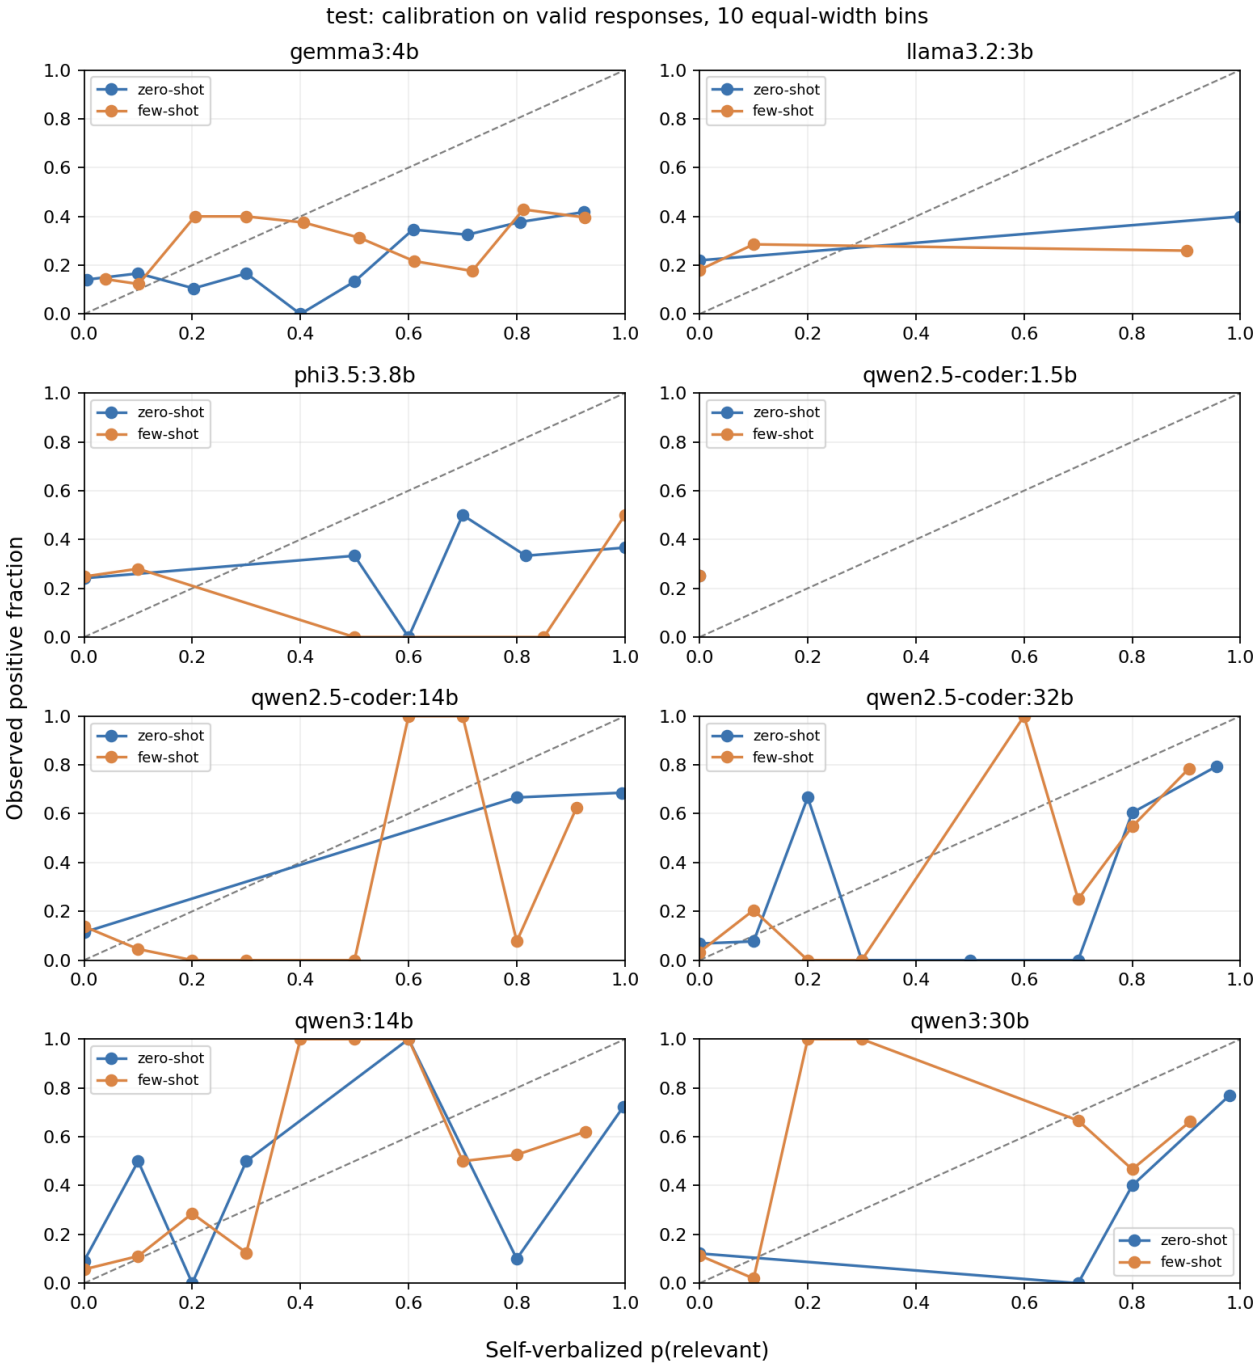


Рисунок 2 Калибровка заявленной уверенности моделей на test

Модель	Few минус zero	95% парный ДИ
Gemma 3 4B	-0,023	[-0,066; 0,025]
Llama 3.2 3B	-0,076	[-0,150; -0,003]
Phi 3.5 3.8B	-0,055	[-0,109; 0,007]
Coder 1.5B	0,000	[0,000; 0,000]
Coder 14B	-0,048	[-0,113; 0,011]
Coder 32B	-0,016	[-0,042; 0,006]
Qwen3 14B	-0,022	[-0,055; 0,005]
Qwen3 30B MoE	-0,012	[-0,058; 0,035]

Few-shot имеет более высокий точечный Macro-F1 у 0 из 8 моделей. Поэтому универсальное улучшение от двух демонстраций не предполагается. Каждая разность оценивается на парных query_id; отсутствие коррекции множественных сравнений ограничивает выводы.

Модель	Реж.	nDCG@10	MRR@10	Recall@3	Recall@10
Gemma 3 4B	F	0,634	0,530	0,423	0,978
Gemma 3 4B	Z	0,686	0,619	0,517	0,969
Llama 3.2 3B	F	0,571	0,472	0,279	0,951
Llama 3.2 3B	Z	0,592	0,481	0,302	0,969
Phi 3.5 3.8B	F	0,555	0,459	0,209	0,969
Phi 3.5 3.8B	Z	0,575	0,472	0,274	0,969
Coder 1.5B	F	0,559	0,449	0,200	0,969
Coder 1.5B	Z	0,559	0,449	0,200	0,969
Coder 14B	F	0,793	0,774	0,633	0,976
Coder 14B	Z	0,841	0,833	0,704	0,996
Coder 32B	F	0,901	0,896	0,780	0,996
Coder 32B	Z	0,900	0,916	0,728	0,992
Qwen3 14B	F	0,825	0,815	0,679	0,996
Qwen3 14B	Z	0,854	0,863	0,704	0,992
Qwen3 30B MoE	F	0,794	0,753	0,677	0,992
Qwen3 30B MoE	Z	0,863	0,886	0,655	0,990

Парные разности few-shot минус zero-shot и интервалы приведены в results/paired_comparisons.csv. Few-shot не считается улучшением только по росту точечной оценки: учитываются ширина интервала и изменение задержки.

6 Выбор модели и анализ ошибок

Выбор выполнен только на 16 validation-запросах до запуска test. Среди пар модель/режим с invalid ≤ 5% максимизируется U = 0,55 Macro-F1 + 0,15 (MCC+1)/2 + 0,15 (1−Brier) + 0,10 (1−p95/max p95) + 0,05 (1−VRAM/max VRAM). Максимумы для нормировки взяты только по validation. При ничьей применяется детерминированный порядок в коде; порог 0,5 не настраивается по test.

Зафиксирован выбор Qwen3 14B в режиме few-shot. На test: Macro-F1 0,769, MCC 0,544, Brier 0,160, p95 3,36 с. Выбранная пара переносится без замены по итогам test. Это решение для локального прототипа, а не универсальный рейтинг LLM.

Кандидат validation	Macro-F1	Brier	p95 с	Utility
Qwen3 14B few-shot	0,714	0,168	3,51	0,693
Coder 14B zero-shot	0,711	0,180	3,64	0,686
Coder 32B zero-shot	0,775	0,138	5,94	0,672
Llama 3.2 3B zero-shot	0,614	0,214	1,31	0,671
Qwen3 30B MoE zero-shot	0,705	0,199	2,96	0,670
Qwen3 14B zero-shot	0,688	0,189	3,99	0,663
Coder 32B few-shot	0,758	0,145	5,77	0,662
Coder 14B few-shot	0,616	0,251	3,43	0,613

Кандидат validation	Macro-F1	Brier	p95 с	Utility
Qwen3 30B MoE few-shot	0,606	0,244	3,29	0,591
Phi 3.5 3.8B few-shot	0,493	0,220	2,07	0,568
Coder 1.5B few-shot	0,440	0,214	0,99	0,565
Coder 1.5B zero-shot	0,438	0,220	0,92	0,561
Llama 3.2 3B few-shot	0,482	0,310	1,47	0,559
Gemma 3 4B few-shot	0,487	0,338	1,94	0,556
Phi 3.5 3.8B zero-shot	0,482	0,282	2,10	0,548
Gemma 3 4B zero-shot	0,481	0,338	2,55	0,544

Модель	Смена класса %	Среднее |Δp|	Δ Macro-F1
Gemma 3 4B	24,4	0,282	-0,020
Llama 3.2 3B	13,4	0,134	-0,093
Phi 3.5 3.8B	9,8	0,098	0,038
Coder 1.5B	0,0	0,000	0,000
Coder 14B	3,7	0,040	-0,022
Coder 32B	1,2	0,037	0,014
Qwen3 14B	2,4	0,024	0,028
Qwen3 30B MoE	4,9	0,059	-0,023

Для первых восьми запросов каждой evaluation-части у всех моделей повторён zero-shot с альтернативной формулировкой смысловой инструкции. Данные, порядок, формат и бюджет сохранены; проверяются доля сменившихся классов и изменение качества. Полные результаты находятся в results/robustness.csv. Проверка касается формулировки инструкции, а не независимого многоязычного переноса или произвольной атаки на prompt.

Запрос dev:1711: На какой реке расположен Тольятти?

Фрагмент «Комсомольский район (Тольятти)»: Расположен на востоке города непосредственно на берегу Волги. Из всех районов города является нижним по течению реки. На западе граничит с Центральным районом города, на востоке окружён Ставропольским районом Самарской области, где район выходит на федеральную автодорогу и плотину Жигулёвской ГЭС.

Эталон 1, прогноз 0, p=0,000. Текст ошибки взят из реально показанного модели входа.

Запрос dev:2212: В каком году родился Льюис Карл Дэвидсон Хэмилтон?

Фрагмент «Хэмилтон, Льюис»: Льюис Карл Дэвидсон Хэмилтон MBE (, иногда имя транскрибируют как "Льюис Гамильтон"; род. 7 января 1985) — британский автогонщик, пилот команды Mercedes AMG Petronas Motorsport. Пятикратный чемпион мира 2008, 2014, 2015, 2017 и 2018 годов. Считается одним из лучших гонщиков за всю историю Формулы-1.

Эталон 1, прогноз 0, p=0,000. Текст ошибки взят из реально показанного модели входа.

Запрос dev:2212: В каком году родился Льюис Карл Дэвидсон Хэмилтон?

Фрагмент «Хольмдаль, Эмиль Льюис»: Родился в 1883 году в городе Форт-Додж, штат Айова, в семье потомков эмигрантов шведского происхождения. В детстве получил лишь незначительное образование. Ещё до завершения обучения в средней школе последовал

призыву президента Маккинли к американским гражданам отправиться на войну против Испании. Солгав относительно своего возраста, поступил в 51-й добровольческий пехотный полк Айовы в 1898 году вместе со своим старшим братом Монти. На Филиппины прибыл несколько месяцев спустя. После победы на испанскими войсками, достигнутой совместно с местными повстанцами, американская армия заняла Филиппины, и население, стремившееся к независимости и недовольное оккупацией, подняло восстание. В 1900 году Хольмдаль на некоторое время покинул Филиппины, находясь в составе американских войск, отправленных на подавление Ихэтуаньского восстания в Китай, а затем вернулся на архипелаг, где участвовал в с

Эталон 0, прогноз 1, p=1,000. Текст ошибки взят из реально показанного модели входа.

Разрез	Значение	Пар	Покрытие	Доля ошибок	Brier
true_class	0	311	1,000	0,158	0,136
original_text_chars	501-900	169	1,000	0,207	0,176
query_type_heuristic	when	137	1,000	0,146	0,121
original_text_chars	<=500	122	1,000	0,221	0,188
true_class	1	105	1,000	0,267	0,230
original_text_chars	>900	125	1,000	0,120	0,110
query_type_heuristic	other	208	1,000	0,188	0,168
query_type_heuristic	who	40	1,000	0,300	0,251
query_type_heuristic	where	31	1,000	0,194	0,156

На отдельном срезе application из 20 запросов классификатор получает Macro-F1 0,765 с 95% ДИ [0,691; 0,838], MCC 0,536 и Brier 0,162. Пара модель/режим не менялась после validation.

В dev:1711 модель отвергла пассаж о районе Тольятти, хотя в нём прямо названа Волга. В dev:2212 дата рождения нужного Хэмилтона получила 0, а год рождения другого человека по имени Льюис — 1. Это наблюдаемые ошибки связи сущности и факта. Их точную внутреннюю причину без контрфактических проверок установить нельзя.

Первые два ошибочно отвергнутых текста содержат 298 и 303 символа и не усечены. Следовательно, эти ошибки нельзя объяснить лимитом 900 символов. Крайние оценки 0 и 1 при неверном решении показывают риск чрезмерной заявленной уверенности.

Разрезы по истинному классу, исходной длине текста и типу вопроса сохранены в results/error_slices.csv. Для длинных пассажей усечение — самостоятельная угроза валидности. Весь набор русский, поэтому сравнение языков по нему невозможно. Пункт методички о типах финансового сообщения адаптирован к области ВКР: вместо финансовой тональности используется релевантность, вместо жанра финансовой новости — тип вопроса Wikipedia.

7 Применение выбранной модели к поиску

На application используются 20 новых запросов и фиксированный корпус 41 007 пассажей. В индекс входят исторически размеченные пассажи train/dev, но на каждом шаге модель видит только реальную выдачу BM25, без меток. Положительные документы не вставляются по query_id. Корпус построен из исторического judged pool, поэтому опыт легче полнокорпусного MIRACL и не сопоставим с его leaderboard.

Исходный запрос выполняется BM25. Модель наблюдает пять коротких результатов и выбирает search с новым запросом либо stop. Максимум — три обращения к индексу, два решения LLM. Повтор запроса, ошибка формата или исчерпание бюджета завершают цикл. Финальный список объединяется RRF с k=60. Сравниваются исходный BM25 и детерминированное расширение по заголовкам с тем же максимальным бюджетом.

Метод	nDCG@10 и ДИ	Recall@10	MRR	Поисков	LLM	Время с
BM25	0,455 [0,312; 0,595]	0,613	0,520	1,00	0,00	0,0018
Расширение заголовками	0,453 [0,313; 0,590]	0,629	0,519	2,55	0,00	0,0042
LLM с обратной связью	0,537 [0,404; 0,659]	0,719	0,612	1,70	1,40	1,7716

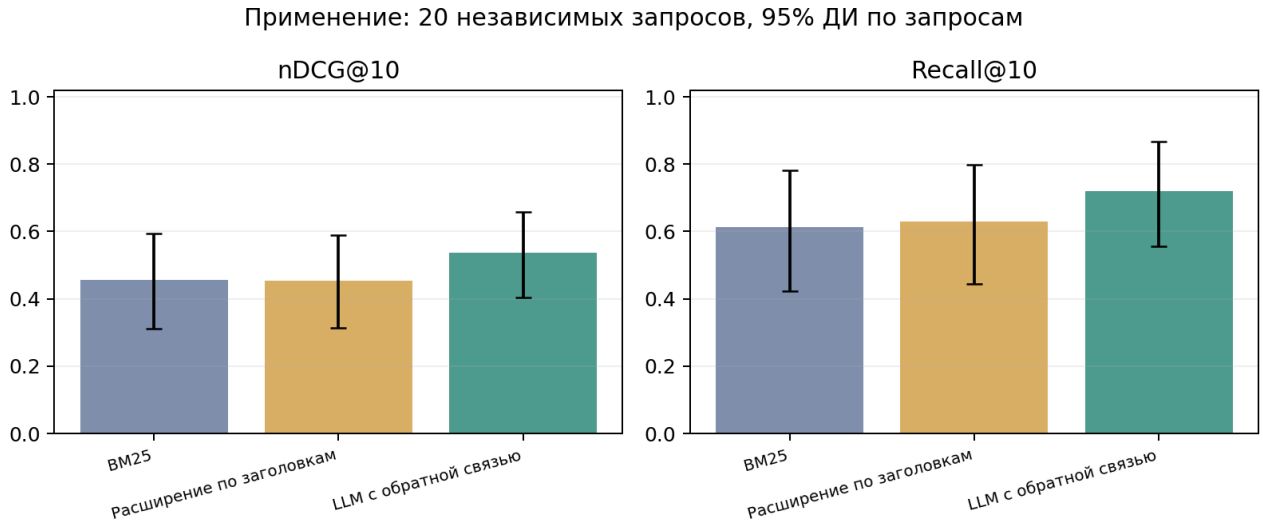


Рисунок 3 Поиск на двадцати новых запросах и 95% интервалы

По сравнению с BM25 разность nDCG@10 равна 0,081 с парным ДИ [0,010; 0,164]; улучшений 4, совпадений 15, ухудшений 1 из 20.

По сравнению с Расширение заголовками разность nDCG@10 равна 0,083 с парным ДИ [0,013; 0,161]; улучшений 10, совпадений 7, ухудшений 3 из 20.

Доля top-10 с известной оценкой равна 0,525. При подсчёте TREC-метрик неразмеченные документы получают нулевой gain; это техническое соглашение при неполных qrels, а не доказательство их нерелевантности.

Пример многошаговой траектории dev:3867: Что вызывает болéзнь Паркинсóна? Поисковые запросы: Что вызывает болéзнь Паркинсóна? → причины болезни Паркинсона → причины развития болезни Паркинсона. Завершение: budget_exhausted.

При интеграции в ВКР сохраняются search → observation → action → stop, версия индекса и бюджет действий. Прототип должен передавать сомнительные случаи на проверку при невалидном ответе, повторении запроса, отсутствии свидетельств или исчерпании бюджета. Поиск не выдаётся за доказанно правильный финальный ответ: MIRACL не содержит необходимых answer labels.

8 Параметрически эффективная адаптация

Дополнительный контроль — Qwen2.5-0.5B-Instruct до и после настоящей LoRA-адаптации. Он не подменяет восьмимодельный опыт: используются отдельная малая модель, другой inference engine и token-aware вход до 256 токенов. Обучение: 128 train-пар, по одной положительной и отрицательной на запрос; rank 8 на q_proj/v_proj, AdamW, learning rate 10^{-4}, одна эпоха, не более 64 шагов, seed 42.

Цель — бинарная cross-entropy по логитам следующих токенов 0 и 1. Вероятность определяется softmax только над этими двумя токенами. Это другая шкала, чем сообщаемая JSON-уверенность основного опыта. Test не используется для настройки. Балансировка train меняет априорную частоту класса относительно естественного test; Brier может ухудшиться. Выполнена LoRA, не QLoRA: квантованное обучение не имитируется названием.

Часть	Состояние	Macro-F1 и ДИ	MCC	Brier	ECE
validation	base	0,278 [0,211; 0,349]	0,151	0,478	0,559
validation	adapted	0,529 [0,447; 0,607]	0,168	0,244	0,287
test	base	0,243 [0,206; 0,281]	0,053	0,522	0,573
test	adapted	0,509 [0,448; 0,566]	0,166	0,250	0,263
application	base	0,301 [0,232; 0,374]	0,023	0,454	0,486
application	adapted	0,569 [0,475; 0,647]	0,190	0,244	0,198

В LoRA-контроле при лимите 256 токенов усечено 92,1% тестовых пассажей. Инструкция и вопрос сохраняются, но модель часто видит лишь начало фрагмента. Это существенное ограничение переноса и дополнительная причина не сравнивать его напрямую с основным опытом.

Выполнено 64 шагов; обучаемых параметров 540,672 из 494,573,440. Обучение заняло 9,8 с на cuda. Наблюдаемый максимум RSS процесса 1,58 ГиБ; это оперативная память, а не VRAM.

Изменение тестового Macro-F1 после LoRA равно 0,266. Это фактический результат короткой адаптации; по одной малой модели и одной эпохе нельзя делать вывод о всех способах PEFT.

9 Ограничения и связь с ВКР

Сорок тестовых запросов дают широкие интервалы. Отбор запросов с обоими классами и строгая проверка утечек меняют исходное распределение; на запросы без положительных документов результат не распространяется.

Основная классификация получает размеченный пул и не измеряет candidate recall. Почти насыщенный Recall@10 нельзя трактовать как успех retrieval. В поисковом опыте ограниченный корпус содержит все исторически размеченные документы, но qrels для других документов неполны.

Один детерминированный порядок кандидатов устраняет разницу между моделями, но не оценивает устойчивость к перестановкам. Few-shot и усечение могут смещать оценки. Возможна неизвестная утечка MIRACL/Wikipedia в предобучение.

Измеряется конкретная локальная сборка с её шаблоном и квантованием. Модели не охватывают всё разнообразие LLM. Задержка одного запроса включает серверные накладные расходы; для многопользовательской нагрузки нужен отдельный throughput benchmark.

Последовательный поиск с обратной связью не равен multi-hop QA. Для ВКР следующий опыт должен использовать ответы и несколько необходимых свидетельств, отдельные teacher trajectories и оценку политики до и после SFT/QLoRA.

Максимальный точечный Macro-F1 на test получен у Coder 32B zero-shot: 0,823. Зафиксированная по validation пара имеет 0,769. Её p95 3,36 с против 5,63 с, resident VRAM 9,77 против 20,28 ГиБ. Максимум качества и практический выбор по нескольким критериям здесь различаются; test не используется для замены выбранного режима.

В проверке H1 few-shot улучшил точечный Macro-F1 у 0 из 8 моделей, ухудшил у 7, не изменил у 1. Для данной пары демонстраций гипотеза об общем преимуществе few-shot не подтвердилась. Интервалы большинства различий включают ноль; перенос вывода на другие демонстрации не проверен.

10 Выводы и воспроизведение

Основной результат — воспроизводимое сравнение восьми локальных моделей в двух режимах и выбор Qwen3 14B по заранее заданному многокритериальному правилу. Результаты классификации, условного reranking и инструментального поиска представлены раздельно. Обзор пятнадцати работ обосновывает дальнейшее обучение именно поисковой политики на проверенных траекториях.

Источник всех таблиц — results/predictions.jsonl, summary.json, search- и peft-артефакты. Данные и хеши находятся в data/prepared/passport.json, параметры — в configs, воспроизведение и проверки — в README.md. Матрица литературы содержит реальные научные источники и ссылки на код.

Репозиторий проекта: https://github.com/NikitaGavrilenko/lab1-llm-miracl. Код, конфигурации, данные и фактические результаты доступны в репозитории. Полная копия проекта также приложена к отчёту.

Список источников

[1] Xinyu Zhang, Nandan Thakur, Odunayo Ogundepo, Ehsan Kamalloo, David Alfonso-Hermelo, Xiaoguang Li, Qun Liu, Mehdi Rezagholizadeh, Jimmy Lin. MIRACL: A Multilingual Retrieval Dataset Covering 18 Diverse Languages. Transactions of the Association for Computational Linguistics, 11, 1114–1131, 2023. https://aclanthology.org/2023.tacl-1.63/ Код: https://github.com/project-miracl/miracl

[2] Nandan Thakur, Nils Reimers, Andreas Rücklé, Abhishek Srivastava, Iryna Gurevych. BEIR: A Heterogeneous Benchmark for Zero-shot Evaluation of Information Retrieval Models. NeurIPS 2021 Datasets and Benchmarks, 2021. https://openreview.net/forum?id=wCu6T5xFjeJ Код: https://github.com/beir-cellar/beir

[3] Vladimir Karpukhin, Barlas Oğuz, Sewon Min, Patrick Lewis, Ledell Wu, Sergey Edunov, Danqi Chen, Wen-tau Yih. Dense Passage Retrieval for Open-Domain Question Answering. EMNLP 2020,

6769–6781, 2020. https://aclanthology.org/2020.emnlp-main.550/ Код: https://github.com/facebookresearch/DPR

[4] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, Sebastian Riedel, Douwe Kiela. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. NeurIPS 2020, Advances in Neural Information Processing Systems 33, 2020. https://papers.nips.cc/paper/2020/hash/6b493230205f780e1bc26945df7481e5-Abstract.html Код: https://github.com/huggingface/transformers/blob/v4.40.2/src/transformers/models/rag/modeling_rag.py

[5] Omar Khattab, Christopher Potts, Matei Zaharia. Baleen: Robust Multi-Hop Reasoning at Scale via Condensed Retrieval. NeurIPS 2021, 2021. https://arxiv.org/abs/2101.00436 Код: https://github.com/stanford-futuredata/Baleen

[6] Luyu Gao, Xueguang Ma, Jimmy Lin, Jamie Callan. Precise Zero-Shot Dense Retrieval without Relevance Labels. ACL 2023, 1762–1777, 2023. https://aclanthology.org/2023.acl-long.99/ Код: https://github.com/texttron/hyde

[7] Xinbei Ma, Yeyun Gong, Pengcheng He, Hai Zhao, Nan Duan. Query Rewriting in Retrieval-Augmented Large Language Models. EMNLP 2023, 5303–5315, 2023. https://aclanthology.org/2023.emnlp-main.322/ Код: https://github.com/xbmxb/RAG-query-rewriting

[8] Weiwei Sun, Lingyong Yan, Xinyu Ma, Shuaiqiang Wang, Pengjie Ren, Zhumin Chen, Dawei Yin, Zhaochun Ren. Is ChatGPT Good at Search? Investigating Large Language Models as Re-Ranking Agents. EMNLP 2023, 14918–14937, 2023. https://aclanthology.org/2023.emnlp-main.923/ Код: https://github.com/sunnweiwei/RankGPT

[9] Shunyu Yao, Jeffrey Zhao, Dian Yu, Nan Duan, Izhak Shafran, Karthik Narasimhan, Yuan Cao. ReAct: Synergizing Reasoning and Acting in Language Models. ICLR 2023, 2023. https://arxiv.org/abs/2210.03629 Код: https://github.com/ysymyth/ReAct

[10] Bowen Jin, Hansi Zeng, Zhenrui Yue, Jinsung Yoon, Sercan Ö. Arık, Dong Wang, Hamed Zamani, Jiawei Han. Search-R1: Training LLMs to Reason and Leverage Search Engines with Reinforcement Learning. COLM 2025; arXiv:2503.09516v5 от 05.08.2025, 2025. https://arxiv.org/abs/2503.09516 Код: https://github.com/PeterGriffinJin/Search-R1

[11] Mingyang Chen, Tianpeng Li, Haoze Sun, Yijie Zhou, Chenzheng Zhu, Fan Yang, Zenan Zhou, Weipeng Chen, Haofen Wang, Jeff Z. Pan, Wen Zhang, Huajun Chen. ReSearch: Learning to Reason with Search for LLMs via Reinforcement Learning. NeurIPS 2025; arXiv:2503.19470v3, 2025. https://arxiv.org/abs/2503.19470 Код: https://github.com/Agent-RL/ReCall

[12] Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, Weizhu Chen. LoRA: Low-Rank Adaptation of Large Language Models. ICLR 2022, 2022. https://openreview.net/forum?id=nZeVKeeFYf9 Код: https://github.com/microsoft/LoRA

[13] Tim Dettmers, Artidoro Pagnoni, Ari Holtzman, Luke Zettlemoyer. QLoRA: Efficient Finetuning of Quantized LLMs. NeurIPS 2023, 2023. https://arxiv.org/abs/2305.14314 Код: https://github.com/artidoro/qlora

[14] Artem Snegirev, Maria Tikhonova, Anna Maksimova, Alena Fenogenova, Aleksandr Abramov. The Russian-focused embedders’ exploration: ruMTEB benchmark and Russian embedding model

design. NAACL 2025, 236–254, 2025. https://aclanthology.org/2025.naacl-long.12/ Код: https://github.com/embeddings-benchmark/mteb/tree/1.14.12

[15] Ivan Rybin, Vladislav Korablinov, Pavel Efimov, Pavel Braslavski. RuBQ 2.0: An Innovated Russian Question Answering Dataset. ESWC 2021, Lecture Notes in Computer Science 12731, 532–547, 2021. https://publications.hse.ru/chapters/489140352 Код: https://github.com/vladislavneon/RuBQ

Данные MIRACL: https://huggingface.co/datasets/miracl/miracl ; корпус: https://huggingface.co/datasets/miracl/miracl-corpus ; использованное зеркало: https://huggingface.co/datasets/sohey1024/miracl-ru-corpus . Дата проверки источников 18.10.2026.

qwen2.5-coder:1.5b: https://huggingface.co/Qwen/Qwen2.5-Coder-1.5B-Instruct

llama3.2:3b: https://huggingface.co/meta-llama/Llama-3.2-3B-Instruct

gemma3:4b: https://huggingface.co/google/gemma-3-4b-it

phi3.5:3.8b: https://huggingface.co/microsoft/Phi-3.5-mini-instruct

qwen2.5-coder:14b: https://huggingface.co/Qwen/Qwen2.5-Coder-14B-Instruct

qwen3:14b: https://huggingface.co/Qwen/Qwen3-14B

qwen3:30b: https://huggingface.co/Qwen/Qwen3-30B-A3B-Instruct-2507

qwen2.5-coder:32b: https://huggingface.co/Qwen/Qwen2.5-Coder-32B-Instruct